

代理模型替代空间映射 — 技术调研报告

1. 问题背景

1.1 粗模型 vs 细模型

	粗模型	细模型
方法	方向图乘积定理 (AF × Fe)	HFSS 全波仿真 (FEM)
耗时	~ms	~min
精度	忽略互耦	完整电磁模型
用途	优化搜索	验证/精调

1.2 空间映射 (SM) 的尝试与失败

已尝试的方法: Aggressive Space Mapping (ASM)

流程: 粗模型 CMA-ES 优化 → HFSS 评估 → PE (参数提取) → Broyden 更新

失败现象: PSLL 从 -14.05 改善到 -14.90 后收敛停滞，残差范数不下降。

根因分析:

- 映射不光滑:** 互耦效应导致位置→方向图的映射是非线性、非光滑的。Broyden 拟牛顿方法假设映射是光滑的，无法逼近真实 Jacobian。
- 响应空间不匹配:** 标准 SM 对齐 S11 参数（跨频率，一维标量函数），而方向图是角度的函数（18001 维向量），对齐难度大得多。
- PE 陷入局部最优:** 参数提取本身是一个优化问题，对于复杂方向图容易陷入局部最优。

2. 替代方案对比

方法	精度	训练样本	适用规模	实现难度	与现有代码兼容
Kriging (GPR)	高	50-200	≤30 维	低	高 (sklearn)
贝叶斯优化 (BO)	高	增量式	≤30 维	中	高 (BoTorch)
RBF 网络	中	100-500	≤100 维	低	高
神经网络 (NN)	中	1000+	任意	高	中
多保真度 Kriging	高	30-100	≤30 维	中	中
直接代理+CMA-ES	高	200-500	≤50 维	低	最高

3. 推荐方案

首选: Kriging 代理模型 + CMA-ES

理由:

1. 现有代码直接复用: `antopt/optimizer.py` (CMA-ES)、`mapping.py` (stick-breaking)、`pattern.py` (AF 计算) 构成完整管线
2. 样本效率高: 50-200 次 AF 计算即可训练, 比 HFSS 采样快 1000 倍
3. 实现简单: `sklearn.gaussian_process.GaussianProcessRegressor` + Matern 5/2 核
4. 增量更新: 新样本加入后可快速重训练

工作流:

1. LHS 采样 → `mapper.synthesize()` → `positions`
2. AF 计算 → `pattern.fitness()` → PSLL (粗模型)
3. 训练 Kriging: `positions` → PSLL
4. CMA-ES 在 Kriging 上优化 → 候选解
5. 候选解 → AF 验证 → 加入训练集
6. 重复 3-5 直到收敛

关键参数:

- 核函数: Matern 5/2 (适合非光滑 PSLL 景观)
- 初始样本: $10 \times n_vars$ (至少)
- 增量采样: 每轮 5-10 个新样本
- 终止条件: 连续 3 轮无改善

备选: 多保真度 Kriging

如果需要融合粗模型 (AF) 和细模型 (HFSS) 的信息:

- 粗模型: AF 计算 (大量样本, ~ms)
- 细模型: HFSS 仿真 (少量样本, ~min)
- 多保真度 Kriging 自动学习两者关系

4. 与现有代码的集成点

```
antopt/  
├─ optimizer.py      # CMA-ES: minimize() → 直接用于代理模型优化  
├─ mapping.py        # LMMapper: synthesize() → 生成训练样本位置  
├─ pattern.py        # Pattern: linear_af() → 计算训练标签 (PSLL)  
├─ analysis.py       # get_psll() → 目标函数  
└─ surrogate.py      # [新增] Kriging 代理模型
```

新增文件 `antopt/surrogate.py` 需要实现:

- `KrigingSurrogate`: 封装 sklearn GPR
- `surrogate_fitness()`: 替换 pattern fitness 的廉价版本
- `infill_criterion()`: 选择下一个采样点 (EI/UCB)

5. 参考文献

详见 [references.md](#)